

# Unir datos y Pivot de tablas

Curso: Bases para Data Science - Estadística, R y Python

Katherine Morales / Néstor Montaña

Sociedad Ecuatoriana de Estadística

Octubre-2020



**Nota:**

Con *Alt + F* o *Option + F* puede hacer que estas diapositivas ocupen todo el navegador (es decir que se ignore el aspecto de diapositiva que tiene por default la presentación)

# Caso a desarrollar

Curso: Bases para Data Science - Estadística, R y Python

# Ejemplo: Data de transacciones bancarias

El Banco del Pacífico requiere mejorar los tiempos de atención al cliente en ventanilla, para ello ha recolectado esta información anónimamente para cada cajero y transacción realizada.

Le suministran un excel con dos hojas:

1. Tiene los datos de las transacciones, columnas: Sucursal, Cajero, ID\_Transaccion, Transaccion, Tiempo\_Servicio\_seg, Nivel de satisfacción, Monto de la transaccion.
2. Otra hoja que indica si en la sucursal se ha puesto o no el nuevo sistema.

# Ejemplo - Caso Banco: Preeliminaries

- Abrir Jupyter Notebook y crear un nuevo notebook dentro de la carpeta scripts dentro de la carpeta del proyecto creado anteriormente
- Importar paquetes necesarios
- Cambiar el directorio de trabajo al directorio del proyecto (recuerden que para importar requerimos que la carpeta Data se pueda acceder directamente)

```
import os
import math as mt
import numpy as np
import pandas as pd
import scipy.stats
# os.getcwd() # obtener el directorio de trabajo
# os.chdir('ruta/al/proyecto/') # Definir el directorio de trabajo
```

# Ejemplo - Caso Banco: Importar

Importar las hojas de excel que estamos utilizando

```
data_banco_xlsx = pd.read_excel('Data//Data_Banco.xlsx', sheet_name = 'Data')
data_banco_xlsx.head(5)
```

```
##      Sucursal  Cajero  ID_Transaccion  ...  Tiempo_Servicio_seg  Satisfaccion  Monto
## 0           62    4820           2  ...           311.0      Muy Bueno  2889,3
## 1           62    4820           2  ...           156.0           Malo  1670,69
## 2           62    4820           2  ...           248.0      Regular  3172,49
## 3           62    4820           2  ...            99.0      Regular  1764.92
## 4           62    4820           2  ...           123.0      Muy Bueno  1835.69
##
## [5 rows x 7 columns]
```

# Ejemplo - Caso Banco: Importar

Importar las hojas de excel que estamos utilizando

```
data_sucursal = pd.read_excel('Data//Data_Banco.xlsx', sheet_name = 'Data_Sucursal')
data_sucursal.head(5)
```

##	ID_Sucursal	Sucursal	Nuevo_Sistema
## 0	62	Riocentro Sur	No
## 1	85	Centro	Si
## 2	267	Alborada	Si
## 3	443	Mall del Sol	Si
## 4	586	Via Daule	No



# Entender los datos - Ejemplo

Entender los datos y modificar los que tienen mal el tipo de columna.

```
# Ver la estructura del data.frame  
data_banco_xlsx.info()
```

```
## <class 'pandas.core.frame.DataFrame'>  
## RangeIndex: 24299 entries, 0 to 24298  
## Data columns (total 7 columns):  
## Sucursal                24299 non-null int64  
## Cajero                  24299 non-null int64  
## ID_Transaccion          24299 non-null int64  
## Transaccion             24299 non-null object  
## Tiempo_Servicio_seg     24299 non-null float64  
## Satisfaccion            24299 non-null object  
## Monto                   24299 non-null object  
## dtypes: float64(1), int64(3), object(3)  
## memory usage: 1.3+ MB
```

# Entender los datos - Ejemplo

Entender los datos y modificar los que tienen mal el tipo de columna.

```
# Ver la estructura del data.frame  
data_sucursal.info()
```

```
## <class 'pandas.core.frame.DataFrame'>  
## RangeIndex: 5 entries, 0 to 4  
## Data columns (total 3 columns):  
## ID_Sucursal      5 non-null int64  
## Sucursal         5 non-null object  
## Nuevo_Sistema    5 non-null object  
## dtypes: int64(1), object(2)  
## memory usage: 248.0+ bytes
```

# Ejemplo - Manipulación de datos

Lo primero que necesitamos es corregir los tipos de datos, nótese que

- **Monto** tiene una mezcla de "," y "."
- **Sucursal** y **Cajero** deberían ser de tipo character
- **Satisfaccion** debe ser factor ordenado

```
data_banco_xlsx['Monto'].head(4)
```

```
## 0      2889,3
## 1      1670,69
## 2      3172,49
## 3      1764.92
## Name: Monto, dtype: object
```

```
# Modificar la coma por punto en Monto
data_banco_xlsx['Monto'] = data_banco_xlsx['Monto'].replace(',', '.', regex=True)
data_banco_xlsx["Monto"] = pd.to_numeric(data_banco_xlsx.Monto, errors='coerce')
data_banco_xlsx['Monto'].head(4)
```

```
## 0      2889.30
## 1      1670.69
## 2      3172.49
## 3      1764.92
## Name: Monto, dtype: float64
```

# Ejemplo - Manipulación de datos

Lo primero que necesitamos es corregir los tipos de datos, nótese que

- **Monto** tiene una mezcla de "," y "."
- **Sucursal** y **Cajero** deberían ser de tipo character
- **Satisfaccion** debe ser factor ordenado

```
# Modificar a String  
data_banco_xlsx['Sucursal'] = data_banco_xlsx['Sucursal'].astype(str)  
data_banco_xlsx['Cajero'] = data_banco_xlsx['Cajero'].astype(str)  
data_banco_xlsx['ID_Transaccion'] = data_banco_xlsx['ID_Transaccion'].astype(str)
```

# Ejemplo - Manipulación de datos

Lo primero que necesitamos es corregir los tipos de datos, nótese que

- **Monto** tiene una mezcla de "," y "."
- **Sucursal** y **Cajero** deberían ser de tipo character
- **Satisfaccion** debe ser factor ordenado

```
## Dato Categorical
data_banco_xlsx['Satisfaccion'] = pd.Categorical(
    data_banco_xlsx['Satisfaccion'],
    categories= ['Muy Malo', 'Malo', 'Regular', 'Bueno', 'Muy Bueno'],
    ordered=True)
data_banco_xlsx.info()
```

```
## <class 'pandas.core.frame.DataFrame'>
## RangeIndex: 24299 entries, 0 to 24298
## Data columns (total 7 columns):
## Sucursal                24299 non-null object
## Cajero                  24299 non-null object
## ID_Transaccion          24299 non-null object
## Transaccion             24299 non-null object
## Tiempo_Servicio_seg     24299 non-null float64
## Satisfaccion            24299 non-null category
## Monto                   24299 non-null float64
## dtypes: category(1), float64(2), object(4)
## memory usage: 1.1+ MB
```

# Ejemplo - Manipulación de datos

Corregir tipo de dato en data\_sucursal

```
# Modificar a String  
data_sucursal['ID_Sucursal'] = data_sucursal['ID_Sucursal'].astype(str)
```

# Unir Datos

## Introducción al análisis de datos

Curso: Bases para Data Science - Estadística, R y Python

Katherine Morales / Néstor Montaña

# Unir datos

```
df_1 = pd.DataFrame({  
    'Nombre': ['Ana', 'Berni', 'Carlos', 'Daniel', 'Ericka'],  
    'Edad' : [20,19,20,19,18],  
    'Ciudad': ['Gye', 'Uio', 'Cue', 'Gye', 'Cue']  
})  
df_1
```

##	Nombre	Edad	Ciudad
## 0	Ana	20	Gye
## 1	Berni	19	Uio
## 2	Carlos	20	Cue
## 3	Daniel	19	Gye
## 4	Ericka	18	Cue



# Unir datos

```
df_2 = pd.DataFrame({  
    'Nombre': ['Fulton', 'Gilda'],  
    'Ciudad': ['Mach', 'Gye'] ,  
    'Edad' : [21,18]  
})  
df_2
```

```
##      Nombre Ciudad  Edad  
## 0  Fulton    Mach    21  
## 1   Gilda     Gye     18
```

# Unir datos

```
pd.concat([df_1, df_2]) #notese el indice
```

```
##      Ciudad  Edad  Nombre
## 0      Gye    20     Ana
## 1      Uio    19     Berni
## 2      Cue    20     Carlos
## 3      Gye    19     Daniel
## 4      Cue    18     Ericka
## 0      Mach   21     Fulton
## 1      Gye    18     Gilda
##
```

```
## C:/ProgramData/Anaconda3/python.exe:1: FutureWarning: Sorting because non-concatenation axis is not
## of pandas will change to not sort by default.
```

```
##
```

```
## To accept the future behavior, pass 'sort=False'.
```

```
##
```

```
## To retain the current behavior and silence the warning, pass 'sort=True'.
```

# Unir datos

```
pd.concat([df_1, df_2], ignore_index=True)
```

##		Ciudad	Edad	Nombre
## 0		Gye	20	Ana
## 1		Uio	19	Berni
## 2		Cue	20	Carlos
## 3		Gye	19	Daniel
## 4		Cue	18	Ericka
## 5		Mach	21	Fulton
## 6		Gye	18	Gilda

# Unir datos

Aumentar columna que indica origen de la fila

```
pd.concat([df_1, df_2] , keys=['df1', 'df2'])
```


##		Ciudad	Edad	Nombre
##	df1 0	Gye	20	Ana
##	1	Uio	19	Berni
##	2	Cue	20	Carlos
##	3	Gye	19	Daniel
##	4	Cue	18	Ericka
##	df2 0	Mach	21	Fulton
##	1	Gye	18	Gilda

# Unir datos - Merge|Join|Buscarv


- Se tienen dos data.frames con columnas o variables que hacen las veces de “key” o “id” de los mismos
- Se desea agregar al primer conjunto el contenido del segundo conjunto de datos si y sólo si el “key” o “id” del segundo conjunto corresponde con el “key” o “id” del primer conjunto de datos.
- Parecido al Buscarv y Vlookup de excel
- Equivalente al Join de Bases de datos

# Unir datos - Merge|Join|Buscar


Entendiendo los tipos de Join




`inner_join(x, y)`



`left_join(x, y)`



`full_join(x, y)`



`right_join(x, y)`

# Unir datos - Merge|Join|Buscar

Creamos el DF para los ejemplos

```
df_6 = pd.DataFrame({  
    'A': ['Ana', 'Daniel', 'Jose'],  
    'B': [100, 200, 300]  
})  
df_6
```

```
##      A      B  
## 0  Ana  100  
## 1 Daniel 200  
## 2  Jose 300
```

# Unir datos - Inner Join

```
pd.merge(df_1, df_6, left_on='Nombre', right_on= 'A')
```

```
##      Nombre  Edad Ciudad      A      B
## 0      Ana    20    Gye    Ana    100
## 1  Daniel    19    Gye  Daniel    200
```

```
df_1.merge(df_6, left_on='Nombre', right_on= 'A')
```

```
##      Nombre  Edad Ciudad      A      B
## 0      Ana    20    Gye    Ana    100
## 1  Daniel    19    Gye  Daniel    200
```



# Unir datos - Inner Join

```
pd.merge(df_1, df_6, how='inner', left_on='Nombre', right_on='A')  
# df_1.merge(df_6, how='inner', left_on='Nombre', right_on='A')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20	Gye	Ana	100
## 1	Daniel	19	Gye	Daniel	200

# Unir datos - Left Join

```
pd.merge(df_1, df_6, how='left', left_on='Nombre', right_on= 'A')  
# df_1.merge(df_6, how='left', left_on='Nombre', right_on= 'A')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20	Gye	Ana	100.0
## 1	Berni	19	Uio	NaN	NaN
## 2	Carlos	20	Cue	NaN	NaN
## 3	Daniel	19	Gye	Daniel	200.0
## 4	Ericka	18	Cue	NaN	NaN

# Unir datos - Right Join

```
pd.merge(df_1, df_6, how='right', left_on='Nombre', right_on= 'A')  
# df_1.merge(df_6, how='right', left_on='Nombre', right_on= 'A')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20.0	Gye	Ana	100
## 1	Daniel	19.0	Gye	Daniel	200
## 2	NaN	NaN	NaN	Jose	300

# Unir datos - Full Join

```
pd.merge(df_1, df_6, how='outer', left_on='Nombre', right_on= 'A')  
# df_1.merge(df_6, how='outer', left_on='Nombre', right_on= 'A')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20.0	Gye	Ana	100.0
## 1	Berni	19.0	Uio	NaN	NaN
## 2	Carlos	20.0	Cue	NaN	NaN
## 3	Daniel	19.0	Gye	Daniel	200.0
## 4	Ericka	18.0	Cue	NaN	NaN
## 5	NaN	NaN	NaN	Jose	300.0

# Unir datos - Merge|Join|Buscar

Vamos a duplicar un Valor en df\_6 y a replicar los Joins para revisar qué sucede cuando se tiene "key" no únicos

```
df_6 = pd.DataFrame({  
    'A': ['Ana', 'Daniel', 'Jose', 'Ana'],  
    'B': [100, 200, 300, 110]  
})  
df_6
```

##		A	B
## 0		Ana	100
## 1		Daniel	200
## 2		Jose	300
## 3		Ana	110

# Unir datos - Inner Join

```
pd.merge(df_1, df_6, how='inner', left_on='Nombre', right_on= 'A')  
# df_1.merge(df_6, how='inner', left_on='Nombre', right_on= 'A')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20	Gye	Ana	100
## 1	Ana	20	Gye	Ana	110
## 2	Daniel	19	Gye	Daniel	200

# Unir datos - Join

Existe también el método `.join` que concatena usando los índices (index) de los dataframes

```
df_1
```

```
##      Nombre  Edad Ciudad
## 0      Ana    20     Gye
## 1     Berni   19     Uio
## 2    Carlos   20     Cue
## 3   Daniel   19     Gye
## 4   Ericka   18     Cue
```

```
df_6
```

```
##      A      B
## 0    Ana  100
## 1  Daniel  200
## 2    Jose  300
## 3    Ana  110
```

# Unir datos - Join

Existe también el método `.join` que concatena usando los índices (index) de los dataframes

```
#Esto va a dar un resultado erróneo porque  
# .join hace la union usando los índices numéricos  
df_1.join(df_6, how='inner')
```

##	Nombre	Edad	Ciudad	A	B
## 0	Ana	20	Gye	Ana	100
## 1	Berni	19	Uio	Daniel	200
## 2	Carlos	20	Cue	Jose	300
## 3	Daniel	19	Gye	Ana	110



# Unir datos - Join

Existe también el método `.join` que concatena usando los índices (index) de los dataframes

```
# Para usar .join se debe definir los  
# índices en cada dataframe  
df_1.set_index('Nombre').join(df_6.set_index('A'), how='inner')
```

##	Edad	Ciudad	B
## Ana	20	Gye	100
## Ana	20	Gye	110
## Daniel	19	Gye	200

# Unir datos - Join

Existe también el método `.join` que concatena usando los índices (index) de los dataframes

```
# 0 definir el indice en el segundo DF y usar el  
# argumento "on" para definir la columna del 1er DF  
df_1.join(df_6.set_index('A'), on='Nombre', how='inner')
```

##	Nombre	Edad	Ciudad	B
## 0	Ana	20	Gye	100
## 0	Ana	20	Gye	110
## 3	Daniel	19	Gye	200

# Unir datos - Caso de estudio

Vamos a agregar la información de las sucursales a las transacciones

```
data_banco_xlsx= pd.merge( data_banco_xlsx.rename(columns={'Sucursal':'ID_Sucursal'}),  
                           data_sucursal, on='ID_Sucursal')  
#Verificar  
data_banco_xlsx[ ['ID_Sucursal', 'Sucursal']].drop_duplicates()
```

##	ID_Sucursal	Sucursal
## 0	62	Riocentro Sur
## 2838	85	Centro
## 14882	267	Alborada
## 18211	443	Mall del Sol
## 22401	586	Via Daule

# Pivotear los datos

## Introducción al análisis de datos

Curso: Bases para Data Science - Estadística, R y Python

Katherine Morales / Néstor Montaña

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(data_banco_xlsx,
                index=["Sucursal"],
                columns=["Satisfaccion"],
                values= ['Tiempo_Servicio_seg'],
                aggfunc=np.mean)
```

```
##          Tiempo_Servicio_seg
## Satisfaccion      Muy Malo      Malo      Bueno      Muy Bueno
## Sucursal
## Alborada          178.288403  176.860435  ...  182.631086  202.188738
## Centro            149.943312  154.821875  ...  173.950992  171.561675
## Mall del Sol       150.047746  162.763379  ...  185.257154  191.550564
## Riocentro Sur      85.751740   86.350993  ...   92.529240   92.495826
## Via Daule          80.352239   77.351706  ...   82.795337   89.141907
##
## [5 rows x 5 columns]
```

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(data_banco_xlsx,
                index=["Sucursal"],
                columns=["Satisfaccion"],
                values= ['Tiempo_Servicio_seg'],
                aggfunc=np.count_nonzero)
```

##	Tiempo_Servicio_seg				
## Satisfaccion	Muy Malo	Malo	Regular	Bueno	Muy Bueno
## Sucursal					
## Alborada	539.0	848.0	642.0	707.0	593.0
## Centro	1243.0	1968.0	2309.0	3094.0	3430.0
## Mall del Sol	461.0	673.0	823.0	1044.0	1189.0
## Riocentro Sur	431.0	604.0	520.0	684.0	599.0
## Via Daule	335.0	381.0	345.0	386.0	451.0

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(
    data_banco_xlsx,
    index=["Sucursal", "Transaccion"],
    columns=["Satisfaccion"],
    values= ['Tiempo_Servicio_seg'],
    aggfunc=np.count_nonzero)
```

		Tiempo_Servicio_seg ...	
		Muy Malo	Muy Bueno
##			
##	Satisfaccion		
##	Sucursal	Transaccion	
##	Alborada	Cobrar cheque (Cta del Bco)	144.0 ... 232.0
##		Cobro/Pago (Cta externa)	70.0 ... 100.0
##		Deposito	325.0 ... 261.0
##	Centro	Cobrar cheque (Cta del Bco)	154.0 ... 639.0
##		Cobro/Pago (Cta externa)	59.0 ... 516.0
##		Deposito	1030.0 ... 2275.0
##	Mall del Sol	Cobrar cheque (Cta del Bco)	77.0 ... 423.0
##		Cobro/Pago (Cta externa)	37.0 ... 204.0

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(
    data_banco_xlsx,
    index=["Sucursal"],
    columns=["Transaccion", "Satisfaccion"],
    values= ['Tiempo_Servicio_seg'],
    aggfunc=np.count_nonzero)
```

```
##                               Tiempo_Servicio_seg      ...
## Transaccion  Cobrar cheque (Cta del Bco)      ... Deposito
## Satisfaccion                               Muy Malo   Malo  ...   Bueno  Muy  Bueno
## Sucursal
## Alborada                                144.0  277.0  ...    362.0    261.0
## Centro                                154.0  285.0  ...   2059.0   2275.0
## Mall del Sol                           77.0   95.0  ...    574.0    562.0
## Riocentro Sur                         85.0  122.0  ...    390.0    335.0
## Via Daule                             45.0   61.0  ...    256.0    279.0
##
## [5 rows x 15 columns]
```



# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(
    data_banco_xlsx,
    index=["Sucursal"],
    columns=["Transaccion"],
    values= ['Tiempo_Servicio_seg', 'Monto'],
    aggfunc=np.mean)
```

```
##                               Monto    ...  Tiempo_Servicio_seg
## Transaccion  Cobrar cheque (Cta del Bco)  ...                Deposito
## Sucursal                                         ...
## Alborada                2133.384149  ...                129.699062
## Centro                2153.427773  ...                130.383375
## Mall del Sol            2149.999323  ...                129.725190
## Riocentro Sur          1832.281773  ...                65.481672
## Via Daule              1789.757928  ...                67.269174
##
## [5 rows x 6 columns]
```

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(
    data_banco_xlsx,
    index=["Sucursal"],
    columns=["Transaccion"],
    values= ['Tiempo_Servicio_seg', 'Monto'],
    aggfunc=[np.mean, np.count_nonzero],
    margins=True)
```

	mean	...	count_nonzero
	Monto	...	Tiempo_Servicio_seg
Transaccion	Cobrar cheque (Cta del Bco)	...	All
Sucursal		...	
Alborada	2133.384149	...	3329.0
Centro	2153.427773	...	12044.0
Mall del Sol	2149.999323	...	4190.0
Riocentro Sur	1832.281773	...	2838.0
Via Daule	1789.757928	...	1898.0
All	2079.749432	...	24299.0

# Pivot

`pivot_table` permite un funcionamiento parecido a una tabla dinámica de excel, se define lo que va a nivel de filas (index), niveles en las columnas (columns), variables a operar (values) y las funciones para resumir la data a usar (aggfunc)

```
pd.pivot_table(
    data_banco_xlsx,
    index=["Sucursal"],
    columns=["Transaccion"],
    values= ['Tiempo_Servicio_seg', 'Monto'],
    aggfunc= {'Tiempo_Servicio_seg': np.mean,
              'Monto': [np.mean, np.std]}))
```

##		Monto	...	Tiempo_Servicio_seg
##		mean	...	mean
##	Transaccion	Cobrar cheque (Cta del Bco)	...	Deposito
##	Sucursal		...	
##	Alborada	2133.384149	...	129.699062
##	Centro	2153.427773	...	130.383375
##	Mall del Sol	2149.999323	...	129.725190
##	Riocentro Sur	1832.281773	...	65.481672
##	Via Daule	1789.757928	...	67.269174
##				

# Melt and pivot

Melt y pivot son funciones que nos permiten pasar valores de filas a columnas

```
df= pd.DataFrame({  
    'Sucursal': ["Norte", 'Centro', 'Sur'],  
    '2017': [100, 101, 102],  
    '2018': [200, 201, 202],  
    '2019': [300, 301, 302]  
})  
df
```

##	Sucursal	2017	2018	2019
## 0	Norte	100	200	300
## 1	Centro	101	201	301
## 2	Sur	102	202	302

# Melt and pivot

En Melt se definen las columnas que van a ser ahora filas (value\_vars), el resultado es un dataframe "más largo"

```
pd.melt(df, id_vars=['Sucursal'],  
        value_vars=['2017', '2018', '2019'],  
        var_name='Anio',  
        value_name='TotalTransacciones')
```

##	Sucursal	Anio	TotalTransacciones
## 0	Norte	2017	100
## 1	Centro	2017	101
## 2	Sur	2017	102
## 3	Norte	2018	200
## 4	Centro	2018	201
## 5	Sur	2018	202
## 6	Norte	2019	300
## 7	Centro	2019	301
## 8	Sur	2019	302

# Melt and pivot

Pivot es lo contrario de melt, permite convertir los niveles de una columna en nuevas columnas, el resultado es un dataframe "más ancho"

```
dfmelt =pd.melt(df, id_vars=['Sucursal'],  
               value_vars=['2017','2018','2019'],  
               var_name='Anio',  
               value_name='TotalTransacciones')  
  
pd.pivot( dfmelt,  
          index='Sucursal',  
          columns='Anio',  
          values='TotalTransacciones' )
```

```
## Anio      2017  2018  2019  
## Sucursal  
## Centro    101    201    301  
## Norte     100    200    300  
## Sur       102    202    302
```

Fin

Curso: Bases para Data Science - Estadística, R y Python

Katherine Morales / Néstor Montaña